

Wydział ETI, Informatyka, semestr 4

Metody probabilistyczne w informatyce

Wykład

Jerzy Konorski

Katedra Teleinformatyki

pok. 139, jekon@eti.pg.edu.pl, tel. 58 347 2123

Systemy IT i rozkłady prawdopodobieństwa

Bizantyjscy generałowie



Bizantyjscy generałowie



- Korzystamy z **twierdzenia Bayesa**




Toolkit


Zasada maksimum wiarygodności

- *hipotezy* H_1, \dots, H_n – układ zupełny zdarzeń
- zaobserwowano zdarzenie A
- $P(A | H_i)$ możliwe do policzenia
- którą hipotezę przyjąć?
- **zasada maksimum wiarygodności**: wybór na podstawie



$$\max_i P(A | H_i)$$



Toolkit




Twierdzenie Bayesa

uwaga, prawo Stiglera!

- hipotezy H_1, \dots, H_n – układ zupełny zdarzeń
- $P(H_i)$ *prawdopodobieństwa a priori* znane
- zaobserwowano zdarzenie A
- $P(A | H_i)$ łatwe do policzenia
- którą hipotezę przyjąć?


Toolkit



Twierdzenie Bayesa

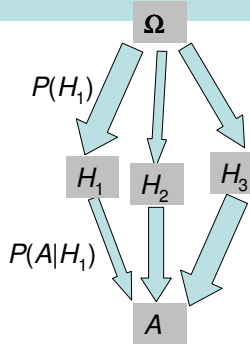
uwaga, prawo Stiglera!

- hipotezy H_1, \dots, H_n – układ zupełny zdarzeń
- $P(H_i)$ *prawdopodobieństwa a priori* znane
- zaobserwowano zdarzenie A
- $P(A | H_i)$ łatwe do policzenia
- którą hipotezę przyjąć?
- **podejście Bayesa**: wybór na podstawie


→ $\max_i P(H_i | A) \leftarrow$ *prawdopodobieństwa a posteriori*


$$P(H_i | A) = \frac{P(A | H_i) \cdot P(H_i)}{\sum_{j=1}^n P(A | H_j) \cdot P(H_j)}, i = 1, \dots, n$$

= P(A), tylko normalizacja!



~ udział miary odpowiedniej "ścieżki dotarcia"


Toolkit




Twierdzenie Bayesa


uwaga, prawo Stiglera!

- $P(H_i | A) \sim P(A | H_i)$ wiarygodność
 $\sim P(H_i)$ wiedza aprioryczna

Np. sygnały z kosmosu! Pulsar vs. Obcy?

- obserwacje kolejnych niezależnych zdarzeń A, B, C, \dots
 dają kolejne przybliżenia do "doskonałej wiedzy *á posteriori*",
 tj. $P(H_i | A)$ jako *á priori* przy obserwacji B itd.
- problem z $P(H_i)$ – skąd brać?


Toolkit




Twierdzenie Bayesa

uwaga, prawo Stiglera!


- $P(H_i | A) \sim P(A | H_i)$ wiarygodność
 $\sim P(H_i)$ wiedza aprioryczna

Np. sygnały z kosmosu! Pulsar vs. Obcy?

- obserwacje kolejnych niezależnych zdarzeń A, B, C, \dots
 dają kolejne przybliżenia do "doskonałej wiedzy *á posteriori*",
 tj. $P(H_i | A)$ jako *á priori* przy obserwacji B itd.
- problem z $P(H_i)$ – skąd brać?
 "aksjomatyści" – z wiedzy apriorycznej, modeli
 "frekwentyści"... radzą nie pamiętać "wzoru Bayesa"!
 - tylko korzystać z zasady maksimum wiarygodności
 i tak definiować A , by $P(A | H_i)$ miało wyraźne maksimum w funkcji i



Toolkit



Twierdzenie Bayesa

uwaga, Prawo Stiglera!

- $P(H_i | A) \sim P(A | H_i)$ wiarygodność
 $\sim P(H_i)$ wiedza aprioryczna

Np. sygnały z kosmosu! Pulsar vs. Obcy?

- obserwacje kolejnych niezależnych zd. dają kolejne przybliżenia do "doskonał. tj. $P(H_i | A)$ jako \hat{a} priori przy obserwac
- problem z $P(H_i)$ – skąd brać?
"aksjomatyści" – z wiedzy apriorycznej
"frekwentyści" ... radzą nie pamiętać "
- tylko korzystać z zasady maksimum
i tak definiować A , by $P(A | H_i)$ miało

360 BULLETIN BIBLIOGRAPHIQUE


E. T. BELL. — *Les grands mathématiciens*. Préface et traduction de Ami Gandillon (Bibliothèque scientifique). — Un vol. in-8°, de vii-615 pages, de Fr. 100.—; Librairie Payot, Paris, 1939.

Intéresser le public cultivé aux sciences mathématiques en lui présentant la vie et les principales découvertes des géomètres les plus célèbres de Zénon à Henri Poincaré, tel est le but de l'ouvrage de M. E. T. Bell, professeur à l'Institut Technologique de Californie. L'auteur met à profit, avec beaucoup de mesure, le goût du jour qui est aux biographies. En dépeignant l'existence des grands mathématiciens, M. Bell laisse entrevoir qu'à côté du savant il y a aussi l'homme avec ses travers petits et grands. Son exposé se compose de 29 notices dont voici les titres:


Introduction. — Zénon, Eudoxe, Archimède, Esprits modernes dans des cerveaux anciens. — Descartes, gentilhomme, soldat, mathématicien. — Fermat, le prince des amateurs. — Pascal, grandeur et misère de l'homme. — Newton sur le rivage. — Leibniz, maître en tous métiers. — Les Bernoulli, nature ou éducation. — Boole, L'Alphabète. — Lagrange, une haute pyramide. — Laplace, du paysan au noble. — Monge et Fourier, amis d'un Empereur. — Poincaré, le jour de gloire. — Gauss, le prince des mathématiciens. — Cauchy, mathématiques et moulins à vent. — Lobatschewsky, le Copernic de la Géométrie. — Abel, génie et pauvreté. — Jacobi, le grand algoriste. — Hamilton, une tragédie irlandaise. — Galois, génie et stupidité. — Cayley et Sylvester, les jumeaux des invariants. — Weierstrass et Sonia Kowalewski. — Boole, complète indépendance. — Hermite, l'homme et non pas la méthode. — Kronecker, le sceptique. — Riemann, âme candide. — Kummer et Dedekind, l'arithmétique qui vient en second lieu. — Poincaré, le dernier savant universel. — Cantor, paradis perdu ?

D'une lecture très attachante, l'édition française, rédigée avec beaucoup de soin par M. Ami Gandillon, ne peut manquer d'intéresser tous ceux qui sont curieux de l'histoire des sciences.

H. FERR.



Systemy IT i rozkłady prawdopodobieństwa



Bizantyjscy generałowie

- Korzystamy z **twierdzenia Bayesa**

- **układ zupełny** hipotez: H_i = w systemie jest i BG, $i = 0..100$
- prawdopodobieństwa \hat{a} priori H_i : $P(H_i) = P(\underline{B}_{100,p} = i) = b_{100,p}(i)$
- zapytanie generuje wielkość losową $\underline{R} \in \{0..100\}$: # niepoprawnych odpowiedzi (zdarzenie zaobserwowane: $\underline{R} = k$)

Bizantyjscy generałowie



- Korzystamy z **twierdzenia Bayesa**

- **układ zupełny** hipotez: H_i = w systemie jest i BG, $i = 0..100$
- **prawdopodobieństwa a priori** H_i : $P(H_i) = P(B_{100,p} = i) = b_{100,p}(i)$
- zapytanie generuje wielkość losową $\underline{R} \in \{0..100\}$: # niepoprawnych odpowiedzi
(zdarzenie zaobserwowane: $\underline{R} = k$)


- **wiarygodność** H_i : $P(\underline{R} = k | H_i) = \sum_{\substack{j=0 \\ k-j=0..100-i}}^i b_{i,1-\varepsilon}(j) b_{100-i,\varepsilon}(k-j)$

j BG nie doznało przekłamania,
 $k-j$ uczciwych agentów doznało

- **prawdopodobieństwa a posteriori**:


$$P(H_i | \underline{R} = k) = \frac{P(\underline{R} = k | H_i) P(H_i)}{\sum_{l=0}^{100} P(\underline{R} = k | H_l) P(H_l)}$$

Bizantyjscy generałowie



mniejsza liczba
niepoprawnych odpowiedzi
faworyzuje mniejsze liczby
BG i zmniejsza niepewność

Bizantyjscy generałowie




mniejsza liczba
niepoprawnych odpowiedzi
faworyzuje mniejsze liczby
BG i zmniejsza niepewność




- ... tymczasem według **zasady maksimum wiarygodności** należy porównywać $P(\underline{R} = k | H_i)$ dla różnych i

wskutek niewykorzystania
znajomości p domniemania
koncentrują się bliżej $i = k$




System reputacyjny Beta



- interakcje agentów z klientami w celu świadczenia usług
- agenci: eksperci / węzły sieci / inteligentne urządzenia / wirtualni operatorzy / ...
- usługi dla klientów: transfer danych / wyszukiwanie informacji / dostęp do zasobów / ekspertyzy / pośrednictwo / ...
- wymagania: rosnące (złożoność, QoS, bezpieczeństwo, ...)
- potrzebny: system budowy zaufania

System reputacyjny Beta



Model agenta ("eksperta"):

- rzetelność z
= $P(\text{dostarcza usługi dające WYSOKĄ satysfakcję})$
- potrzebujemy rozkładu prawdopodobieństwa z - ciągła wielkość losowa!

raport o satysfakcji
WYSOKA / NISKA

Centrum
Reputacji




Gęstość prawdopodobieństwa

- wielkości losowe ciągłe



- Czy istnieje funkcja $p(x) \geq 0$ taka, że $P(a \leq X \leq b) = \int_a^b p(x) dx$?



$$p(x) = \frac{P(x \leq X < x + dx)}{dx}$$

$$\int_{-\infty}^{\infty} p(x) dx = P(-\infty < X < \infty) = 1 \quad \text{warunek normalizacyjny}$$



Dystrybuanta

- **dystrybuanta** (funkcja rozkładu): $F(x) = P(\underline{X} < x)$
 - niemalejąca
 - lewostronnie ciągła
 - $F(x) = 0, F(x) = 1$ na krańcach dziedziny
- **komplementarna dystrybuanta**: $C(x) = 1 - F(x) = P(\underline{X} \geq x)$




Dystrybuanta

➡ **związki między p, F i C**

$$p(x) = \frac{d}{dx} F(x)$$

$$F(x) = \int_{-\infty}^x p(u) du$$

$$C(x) = \int_x^{\infty} p(u) du$$






Toolkit



Wartość średnia ciągłej wielkości losowej



$$E\underline{X} = \int_{-\infty}^{\infty} x \cdot p(x) dx$$



Toolkit



Wartość średnia ciągłej wielkości losowej

- Rozkład...

- wykładniczy: $E\underline{X} = \int_0^{\infty} x \cdot e^{-x/m} / m \cdot dx = m$

- normalny $N(m, \sigma)$: $E\underline{X} = \int_{-\infty}^{\infty} x \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-m)^2 / 2\sigma^2} dx = m$

- Pareto: $p(x) = \begin{cases} 0, & x < a \\ \frac{b}{a} \left(\frac{a}{x}\right)^{b+1}, & x \geq a \end{cases}$

- itd.

$$\int_{-\infty}^{\infty} e^{-x^2} dx = \sqrt{\pi}$$



Wartość średnia ciągłej wielkości losowej

- Czy wartość średnia jest...
 - najbardziej prawdopodobna? r. wykładniczy !
 - skończona? r. Pareto, $b \leq 1$!

$$EX = \int_a^{\infty} x \frac{b}{a} \left(\frac{a}{x} \right)^{b+1} dx = \frac{b}{a} \cdot \frac{1}{b-1}$$

- Czy wartość średnia zawsze istnieje?

$$EX = \int_{-\infty}^{\infty} x \cdot \frac{1}{\pi} \frac{1}{1+x^2} dx =$$

rozkład Cauchy'ego



Twierdzenie o średniej warunkowej

- Analogicznie do prawdopodobieństwa całkowitego:

$$\Rightarrow EX = \int_{-\infty}^{\infty} \underset{\substack{\uparrow \\ \text{wartość średnia warunkowego rgp } p_X(x|y)}}{EX|y} \cdot p_Y(y) dy$$



Twierdzenie o średniej warunkowej

Z tw. o średniej warunkowej możemy wywnioskować:

- $E(a\underline{X} + b\underline{Y} + c) = aE\underline{X} + bE\underline{Y} + c$
w szczególności:



$$E(\underline{X} + \underline{Y} + \dots) = E\underline{X} + E\underline{Y} + \dots$$



$$E(a\underline{X} + b) = \int_{-\infty}^{\infty} (ax + b) \cdot p(x) dx = aE\underline{X} + b$$

(E – operator liniowy!)



Wartość średnia: uogólnienie


- Dla dowolnego przekształcenia g : $Eg(\underline{X}) = \int_{-\infty}^{\infty} g(x) \cdot p(x) dx$

Z tw. o średniej warunkowej:



- $\underline{X}, \underline{Y}$ niezależne $\Rightarrow E(g(\underline{X}) \cdot g(\underline{Y})) = Eg(\underline{X}) \cdot Eg(\underline{Y})$ (tylko \Rightarrow !)
w szczególności $E(\underline{X} \cdot \underline{Y}) = E\underline{X} \cdot E\underline{Y}$

System reputacyjny Beta



Model agenta ("eksperta"):

- rzetelność z
= $P(\text{dostarcza usługi dające WYSOKĄ satysfakcję})$
- potrzebujemy rozkładu prawdopodobieństwa z - ciągła wielkość losowa!
- statystyczna niezależność zachowań w kolejnych interakcjach
- \Rightarrow liczby \underline{W} i \underline{N} raportów o WYSOKIEJ i NISKIEJ satysfakcji klientów z usług tego agenta są **wielkościami losowymi Bernoulliego**
- gdy $\underline{W} = w$ i $\underline{N} = n$, ocena agenta = $z^*(w, n)$

raport o satysfakcji
WYSOKA / NISKA

Centrum
Reputacji


System reputacyjny Beta

Do wypracowania oceny z^* wykorzystuje się **twierdzenie Bayesa**.

Odnosnie z mamy ciągły **układ zupełny** hipotez: $z \in [0, 1]$.

Przyjmijmy jednakowe prawdopodobieństwa a priori: $p(z) = \text{const.}$

Zdarzenie zaobserwowane: $\underline{W} = w, \underline{N} = n$



System reputacyjny Beta




Do wypracowania oceny z^* wykorzystuje się **twierdzenie Bayesa**.



Odnosnie z mamy **ciągły układ zupełny** hipotez: $z \in [0, 1]$.

Przyjmijmy jednakowe prawdopodobieństwa a priori: $p(z) = \text{const.}$

Zdarzenie zaobserwowane: $\underline{W} = w, \underline{N} = n$




$$p(z | w, n) = \frac{P(\underline{W} = w, \underline{N} = n | z) p(z)}{\int_0^1 P(\underline{W} = w, \underline{N} = n | x) p(x) dx} = \frac{\binom{w+n}{w} z^w (1-z)^n}{\int_0^1 \binom{w+n}{w} x^w (1-x)^n dx}$$

$$= \frac{(w+n+1)!}{w!n!} z^w (1-z)^n = \text{Beta}_{w,n}(z)$$

$= 1/(w+n+1)$



System reputacyjny Beta



rozkład beta

- Ocena z :

$$z^*(w, n) = E Z = \int_0^1 z \cdot p(z | w, n) dz = \frac{w+1}{w+n+2}$$


System reputacyjny Beta

Problem: niektórzy klienci mogą być nieuczciwi i składać fałszywe raporty, np.:

- "oszczerca": wysoką satysfakcję raportuje jako WYSOKĄ w 50% przypadków
- "wspólnik": niską satysfakcję raportuje jako NISKĄ w 50% przypadków

Przykład

- rzetelność eksperta Jana K. wynosi $z = 0.6$
- klienci $i \in I$ składają raporty nt. Jana K.
- po 40 rundach składania raportów:



klient i	w_i	n_i	"oszczerca"?
1	15	25	
2	30	10	
3	22	18	
4	25	15	
5	24	16	
6	23	17	
7	19	21	
8	25	15	
9	20	20	
10	22	18	
suma	225	175	
ocena $z^*(I)$	0.56		"wspólnik"?



Jak Centrum Reputacji ma eliminować efekty raportów nieuczciwych klientów?

dr. Konorski, MPwI wykład

Z wykorzystaniem **kwantyli rozkładu** !

29




Toolkit

Kwantyle rozkładu


- Równanie $F(x) = P(\underline{X} < x) = u$




$\Rightarrow x = K_u$ **kwantyl rzędu u** rozkładu \underline{X}



Poziom bezpieczeństwa,
ryzyko przekroczenia = $1 - \delta$




Minimalne gwarancje,
ryzyko niezapewnienia = δ



Przedział "typowych" realizacji



Kwantyle rozkładu




System reputacyjny Beta

Problem: Jaki zbiór klientów $M \subseteq I$ można uznać za uczciwych?

M jest **największym** podzbiorem I spełniającym warunek

$$z^*(M) \in [\kappa_{(1-\delta)/2}^{(i)}, \kappa_{(1+\delta)/2}^{(i)}] \quad \forall i \in M$$

gdzie $\kappa_u^{(i)}$ – kwantyle rozkładu $Beta_{w_i, n_i}(z)$
 δ – ustalony próg tolerancji




swoiste kryterium większościowe:
 ocena każdego klienta $i \in M$ nie jest wyraźnie
 niezgodna z oceną zbiorową opartą na M

System reputacyjny Beta

```

M := I
repeat
  z* := (Σi∈M wi + 1) / (Σi∈M (wi + ni) + 2)
  nieuczciwi := ∅
  for i ∈ M do
    znajdź kwantyl0.05, kwantyl0.95 rozkładu Betawi, ni(z); //δ = 10%
    if z* < kwantyl0.05 then nieuczciwi ∪ := {i} // "wspólnik";
    if z* > kwantyl0.95 then nieuczciwi ∪ := {i} // "oszczerca"
  M \ := nieuczciwi
until nieuczciwi = ∅

```



J. Konorski, MPwI wykład


33

Generacja liczb pseudolosowych:
metoda odwracania dystrybucy

- Czas życia (bezawaryjnej pracy) badanego systemu jest wielkością losową o dystrybucy:

$$\tilde{F}(x) = 1 - e^{-x^b/a}, \quad x \geq 0$$

tz. **rozkład Weibulla**; parametry: a : (skali), b : (kształtu), popularny w analizie niezawodności, gdyż zależnie od b może modelować różne efekty upływu czasu.



odpowiednia gęstość prawdopodobieństwa


- Jak wygenerować taki czas życia w symulatorze?
- Problem: Dysponujemy generatorem random. Jak przekształcić go w generator wielkości losowej o zadanej dystrybucy $\tilde{F}(\cdot)$?

J. Konorski, MPwI wykład

34


Generacja liczb pseudolosowych: metoda odwracania dystrybucyj

- Zakładamy, że $\tilde{F}(\cdot)$: ciągła & monotoniczna (\Rightarrow odwracalna)
- Niech $\underline{U} \sim \text{random}$, tj. $P(\underline{U} < u) = u \ \forall u \in [0,1]$
- Zdefiniujemy $\underline{X} = \tilde{F}^{-1}(\underline{U})$
- Jaka będzie $F_X(x)$?



Generacja liczb pseudolosowych: metoda odwracania dystrybucyj

- Zakładamy, że $\tilde{F}(\cdot)$: ciągła & monotoniczna (\Rightarrow odwracalna)
- Niech $\underline{U} \sim \text{random}$, tj. $P(\underline{U} < u) = u \ \forall u \in [0,1]$
- Zdefiniujemy $\underline{X} = \tilde{F}^{-1}(\underline{U})$
- Jaka będzie $F_X(x)$?:



$$F_X(x) = P(\underline{X} < x) = P(\tilde{F}^{-1}(\underline{U}) < x) = P(\underline{U} < \tilde{F}(x)) = \tilde{F}(x)$$




kwantyl rzędu u rozkładu $\tilde{F}(\cdot)$

```
u := random;  
x :=  $\tilde{F}^{-1}(u)$   
// dla rozkładu Weibulla  $x := \sqrt[b]{-a \cdot \ln u}$ 
```

- Co gdy $F(\cdot)$ nieciągła / niemonotoniczna? Drobne modyfikacje.

"Naturalne" zbiory danych

to tylko fragment dłuższej listy...



J. Konorski, MPwI wykład

prędkość światła	299792458 m/s
stała grawitacyjna	$6.67259 \cdot 10^{-11} \text{ m}^3/\text{kg}\cdot\text{s}^2$
stała Plancka / 2π	$1.0545726691251 \cdot 10^{-34} \text{ Js}$
masa Plancka	$2.17671 \cdot 10^{-8} \text{ kg}$
długość Plancka	$1.61605 \cdot 10^{-35} \text{ m}$
j.a.	$1.4959789 \cdot 10^{11} \text{ m}$
parsek	206264.806 j.a.
rok świetlny	$9.46053 \cdot 10^{15} \text{ m}$
masa Słońca	$1.989 \cdot 10^{30} \text{ kg}$
średnica Słońca	$1.392 \cdot 10^6 \text{ km}$
promień Bohra	$5.29177249 \cdot 10^{-11} \text{ m}$
atmosfera techniczna	101325 Pa
eV	$1.60217733 \cdot 10^{-19} \text{ J}$
masa protonu	1.0072764666 amu
masa elektronu	$0.000548579911 \text{ amu}$
tunt	0.45359232 kg
j. strumienia magnetycznego	$2.06783461 \cdot 10^{-15} \text{ Wb}$
opór Halla	25812.8056Ω
stała Boltzmanna	$1.380658 \cdot 10^{-23} \text{ J/K}$
stała Avogadro	$6.0221367 \cdot 10^{23} \text{ 1/mol}$
stała Faradaya	$96485.309 \text{ C 1/mol}$

- Pierwsze cyfry znaczące nie występują jednakowo często.
- Ich częstości układają się w pewien "wzorcowy" rozkład (**prawo Benforda**).
- Dlaczego? Co to za rozkład?

37

"Naturalne" zbiory danych

- Niech $\underline{X} > 0$ – wartość przypadkowo wybranej danej z pewnego "naturalnego" zbioru danych. Jaki rozkład prawdopodobieństwa posiada \underline{X} ? (??!!!)

J. Konorski, MPwI wykład

38

"Naturalne" zbiory danych


- Niech $\underline{X} > 0$ – wartość przypadkowo wybranej danej z pewnego "naturalnego" zbioru danych. Jaki rozkład prawdopodobieństwa posiada \underline{X} ? (?!?!)
- Jeżeli \underline{X} posiada jakiś rozkład, to nie może on zależeć od jednostek, w jakich wyrażone są dane!



np. prawdopodobieństwa znalezienia się w lewej połowie skali... lewej / środkowej ćwiartce itd.. są takie same.

"Naturalne" zbiory danych



- Niech $\underline{X} > 0$ – wartość przypadkowo wybranej danej z pewnego "naturalnego" zbioru danych. Jaki rozkład prawdopodobieństwa posiada \underline{X} ? (?!?!)
- Jeżeli \underline{X} posiada jakiś rozkład, to nie może on zależeć od jednostek, w jakich wyrażone są dane!



np. prawdopodobieństwa znalezienia się w lewej połowie skali... lewej / środkowej ćwiartce itd.. są takie same.

- Zatem \underline{X} i $k\underline{X}$ mają takie same rozkłady dla dowolnego $k > 0$.
- $P(\underline{X} < x) = P(k\underline{X} < x) = P(\underline{X} < x/k) \Rightarrow F_X(x) \equiv F_X(x/k)$
- Pamiętając o związkach między gęstością prawdopodobieństwa a dystrybucją mamy po zróżniczkowaniu: $p_X(x) \equiv \frac{p_X(x/k)}{k} \Rightarrow p_X(x) = \frac{c}{x}$

"Naturalne" zbiory danych



$$P(\text{I cyfra znac.} = m \mid 10^i \leq X < 10^{i+1}) = \frac{\int_{10^i}^{10^{i+1}} p_X(x) dx}{\int_{10^i}^{10^{i+1}} p_X(x) dx} = \log(m+1) - \log m$$



• Z twierdzenia o prawdopodobieństwie całkowitym:

$$P(\text{I cyfra znac.} = m)$$

$$= \sum_{i=0, \pm 1, \pm 2, \dots} P(\text{I cyfra znac.} = m \mid 10^i \leq X < 10^{i+1}) P(10^i \leq X < 10^{i+1}) = \log(m+1) - \log m$$

to właśnie rozkład "wzorcowy", $m = 1..9$

Systemy IT i sumy niezależnych wielkości losowych

- wariancja
- funkcje: charakterystyczna i tworząca
- zbieżność stochastyczna, słabe prawo wielkich liczb
- rozkłady: normalny, Erlanga, Pareto, Cauchy'ego
- przekształcenie (funkcja) wielkości losowej

Jaki jest problem i po co jest?

Dane: X, Y niezależne o wspólnej dziedzinie (zbiornie realizacji) i znanych rozkładach. Jaki rozkład ma $Z = X + Y$?



Momenty rozkładu? Wiemy:

Wartość średnia: $EZ = EX + EY$

Wariancja: $VZ = E(Z - EZ)^2 = VX + VY$

Odchylenie standardowe: $\sigma_Z = \sqrt{\sigma_X^2 + \sigma_Y^2}$

Rozkłady sum niezależnych wielkości losowych potrzebne są do analizy:

- zagregowanych losowych strumieni zdarzeń
- łącznych efektów wielu zjawisk losowych
- serii doświadczeń losowych
- itd.


Rozkłady sum niezależnych wielkości losowych

Jeżeli X i Y mają obie rozkład równomierny, to czy rozkład $Z = X + Y$ też jest równomierny (przesunięty/przeskalowany)? Nie.

Wynik rzutu kostką symetryczną ma rozkład równomierny, lecz suma wyników w dwóch rzutach już nie, np. 7 oczek jest znacznie bardziej prawdopodobne niż 2 lub 12.



www.solidhead.com



rozkład sumy oczek w $n = 20$ rzutach



Rozkłady sum niezależnych wielkości losowych

Liczby wywołań:

$$Z = \begin{cases} X \\ Y \end{cases}$$

F=Failure/ E=Event	Date Occurred	Time Occurred	Date Restored	Time Restored	Level 1	Level 2	Level 3	Level 4	OTSF (Y=yes/N=no)
1	F	1/02/10 4:00:00 PM	1/02/10 7:49:00 PM	Pump					N
2	E	1/09/10 8:30:00 AM	1/09/10 10:43:00 AM	Motor					Y
3	F	1/10/10 9:13:00 AM	1/10/10 7:48:00 PM	Motor					Y
4	E	1/12/10 7:26:00 PM	1/12/10 6:46:00 PM	Pump					N
5	F	1/14/10 4:56:00 PM	1/13/10 5:21:00 PM	Pump					N
6	E	1/15/10 1:16:00 PM	1/15/10 4:39:00 PM	Motor					Y
7	F	1/20/10 1:39:00 PM	1/21/10 7:15:00 PM	Pump					N
8	F	1/25/10 10:32:00 AM	1/27/10 10:47:00 PM	Motor					Y
9	E	1/28/10 11:31:00 AM	1/28/10 12:00:00 PM	Pump					N
10	F	2/02/10 2:38:00 PM	2/02/10 7:11:00 PM	Motor					Y
11	E	2/08/10 3:51:00 PM	2/08/10 8:22:00 AM	Pump					N
12	F	2/12/10 4:42:00 PM	2/13/10 9:59:00 AM	Pump					N
13	E	2/17/10 2:47:00 PM	2/17/10 7:13:00 PM	Motor					Y
14	E	2/25/10 4:31:00 PM	2/25/10 5:00:00 PM	Pump					N
15	F	2/28/10 9:00:00 AM	2/28/10 3:10:00 PM	Motor					Y
16	E	3/01/10 10:16:00 AM	3/01/10 10:43:00 AM	Pump					N
17	E	3/02/10 3:41:00 PM	3/02/10 9:11:00 PM	Pump					N
18	F	3/12/10 8:46:00 AM	3/12/10 9:20:00 PM	Motor					Y
19	F	3/13/10 4:45:00 PM	3/13/10 5:13:00 PM	Pump					N
20	E	3/15/10 9:36:00 AM	3/15/10 10:02:00 PM	Motor					Y



- $P(Z = k) = \dots$ rozbijamy względem **układu zupełnego** $P(X = j), j = 0, \dots, k$




Toolkit

Prawdopodobieństwo całkowite

- Interesuje nas dowolne zdarzenie A

$$P(A) = P(AH_1) + \dots + P(AH_n)$$





Rozkłady sum niezależnych wielkości losowych



Liczby wywołań:

$$\underbrace{\begin{matrix} X \\ Z \\ Y \end{matrix}}_{}$$

F=Failure/Event	Date Occurred	Time Occurred	Date Restored	Time Restored	Level 1	Level 2	Level 3	Level 4	OTSF (Y=yes/N=no)
1	F	1/02/10 4:00:00 PM	1/02/10 7:49:00 PM	Pump					N
2	E	1/09/10 8:30:00 AM	1/09/10 10:43:00 AM	Motor					Y
3	F	1/10/10 9:13:00 AM	1/10/10 7:48:00 PM	Motor					Y
4	E	1/12/10 3:26:00 PM	1/12/10 6:46:00 PM	Pump					N
5	F	1/14/10 4:56:00 PM	1/15/10 5:21:00 PM	Pump					N
6	E	1/15/10 1:16:00 PM	1/15/10 4:39:00 PM	Motor					Y
7	F	1/20/10 1:39:00 PM	1/21/10 7:15:00 PM	Pump					N
8	F	1/25/10 10:32:00 AM	1/27/10 10:47:00 PM	Motor					Y
9	E	1/28/10 11:31:00 AM	1/28/10 12:00:00 PM	Pump					N
10	F	2/02/10 2:38:00 PM	2/02/10 7:11:00 PM	Motor					Y
11	E	2/08/10 3:51:00 PM	2/08/10 8:22:00 AM	Pump					N
12	F	2/12/10 4:42:00 AM	2/13/10 9:59:00 AM	Pump					N
13	E	2/17/10 2:47:00 PM	2/17/10 7:13:00 PM	Motor					Y
14	E	2/25/10 4:31:00 PM	2/25/10 5:00:00 PM	Pump					N
15	F	2/28/10 9:00:00 AM	2/28/10 3:10:00 PM	Motor					Y
16	E	3/01/10 10:16:00 AM	3/01/10 10:43:00 AM	Pump					N
17	E	3/02/10 3:41:00 PM	3/02/10 9:11:00 PM	Pump					N
18	F	3/12/10 8:46:00 AM	3/12/10 9:20:00 PM	Motor					Y
19	F	3/13/10 4:45:00 PM	3/13/10 5:13:00 PM	Pump					N
20	E	3/15/10 9:36:00 AM	3/15/10 10:02:00 PM	Motor					Y




• $P(Z = k) = \dots$ rozbijamy względem **układu zupełnego** $P(X = j), j = 0, \dots, k$

$$P(Z = k) = \sum_{j=0}^k P((X = j)(Y = k - j)) = \sum_{j=0}^k P(X = j) \cdot P(Y = k - j)$$

splot dyskretny




Architektura wielordzeniowa



4123 ← w każdym cyklu dostępu
2341 przypadkowa permutacja
2134 szczelin dla rdzeni

chybienie w pamięci podręcznej danych/instrukcji



$$P(AET > MTET) \leq \varepsilon$$


AET – actual execution time $Z = X + Y$

MTET – maximum tolerable execution time

- $F_Z(z) = P(X + Y < z) = \dots$ rozbijamy względem układu zupełnego
 $P(x \leq X < x + dx), 0 \leq x \leq \text{szczelina}$




Architektura wielordzeniowa



4123 → w każdym cyklu dostępu
2341 przypadkowa permutacja
2134 szczelin dla rdzeni

chybienie w pamięci podręcznej danych/instrukcji



$$P(AET > MTET) \leq \varepsilon$$

AET – actual execution time $\underline{Z} = \underline{X} + \underline{Y}$

MTET – maximum tolerable execution time


- $F_Z(z) = P(\underline{X} + \underline{Y} < z) = \dots$ rozbijamy względem układu zupełnego
 $P(x \leq \underline{X} < x + dx)$, $0 \leq x \leq \text{szczelina}$

$$F_Z(z) = P(\underline{X} + \underline{Y} < z) = \int_x P(\underline{Y} < z - x)(x \leq \underline{X} < x + dx)$$

$$= \int_x P(\underline{Y} < z - x)P(x \leq \underline{X} < x + dx) = \int_x F_Y(z - x)p_X(x)dx$$




Architektura wielordzeniowa



4123 → w każdym cyklu dostępu
2341 przypadkowa permutacja
2134 szczelin dla rdzeni

chybienie w pamięci podręcznej danych/instrukcji



$$P(AET > MTET) \leq \varepsilon$$

AET – actual execution time $\underline{Z} = \underline{X} + \underline{Y}$

MTET – maximum tolerable execution time


- $F_Z(z) = P(\underline{X} + \underline{Y} < z) = \dots$ rozbijamy względem układu zupełnego
 $P(x \leq \underline{X} < x + dx)$, $0 \leq x \leq \text{szczelina}$

$$F_Z(z) = P(\underline{X} + \underline{Y} < z) = \int_x P(\underline{Y} < z - x)(x \leq \underline{X} < x + dx)$$

$$= \int_x P(\underline{Y} < z - x)P(x \leq \underline{X} < x + dx) = \int_x F_Y(z - x)p_X(x)dx$$




Sploty rozkładów



splot ma własność łączności
– można splotać wielokrotnie,
uzyskując gęstości prawdopodobieństwa
sum wielu składników losowych

suma z n -krotnego zwrotu `random [0,1)`
(n -krotny splot czerwonej funkcji ze sobą)



Funkcje charakterystyczne i tworzące



Bardziej efektywne podejście do wyznaczania rozkładów sum wielkości losowych opiera się na zdefiniowaniu dla w.l. \underline{X} przekształcenia:

$$g(\underline{X}) = \begin{cases} e^{jv\underline{X}}, & \underline{X} \text{ ciągła o zbiorze realizacji } x \in [a, b] \\ z^{\underline{X}}, & \underline{X} \text{ dyskretna o zbiorze realizacji } x \in \{0, 1, 2, \dots\} \end{cases}$$

gdzie:
 $j^2 = -1$
 $|z| \leq 1$

Zainteresujemy się $Eg(\underline{X})$.

zmienne zespolone
traktujemy w obliczeniach
jak zwykłe zmienne :)



Wartość średnia: uogólnienie

- Dla dowolnego deterministycznego przekształcenia $g(\cdot)$:

$$Eg(X) = \begin{cases} \int_{-\infty}^{\infty} g(x) \cdot p(x) dx \\ \sum_{x_k} g(x_k) \cdot P(X = x_k) \end{cases}$$



Funkcje charakterystyczne i tworzące

Bardziej efektywne podejście do wyznaczania rozkładów sum wielkości losowych opiera się na zdefiniowaniu dla w.l. \underline{X} przekształcenia:

$$g(\underline{X}) = \begin{cases} e^{jv\underline{X}}, \underline{X} \text{ ciągła o zbiorze realizacji } x \in [a, b] \\ z^{\underline{X}}, \underline{X} \text{ dyskretna o zbiorze realizacji } x \in \{0, 1, 2, \dots\} \end{cases}$$

gdzie:
 $j^2 = -1$
 $|z| \leq 1$

Zainteresujemy się $Eg(\underline{X})$.

Funkcja charakterystyczna

$$\varphi_X(v) = Ee^{jv\underline{X}} = \int_a^b e^{jvx} p_X(x) dx$$

zmienne zespolone
traktujemy w obliczeniach
zwyczajnie :)

Funkcja tworząca

$$G_X(z) = Ez^{\underline{X}} = \sum_{k=0}^{\infty} z^k P(\underline{X} = k) = P(\underline{X} = 0) + zP(\underline{X} = 1) + z^2P(\underline{X} = 2) + \dots$$



Funkcje charakterystyczne i tworzące

- Czy dają tyle informacji, co rozkład prawdopodobieństwa? Tak.

– twierdzenie o jednoznaczności: $p_X(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-jux} \cdot \varphi_X(v) dv$

– rozwinięcie w szereg potęgowy: $P(\underline{X} = k) = \frac{G_X^{(k)}(0)}{k!}$



Funkcje charakterystyczne i tworzące

- Czy dają tyle informacji, co rozkład prawdopodobieństwa? Tak.

– twierdzenie o jednoznaczności: $p_X(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-jux} \cdot \varphi_X(v) dv$

– rozwinięcie w szereg potęgowy: $P(\underline{X} = k) = \frac{G_X^{(k)}(0)}{k!}$



- W czym mogą pomóc? W obliczaniu **momentów rozkładu**, np.

$$EX = \begin{cases} \int_a^b xp_X(x)dx = \frac{\varphi'_X(0)}{j} \\ \sum_{k=0}^{\infty} kP(X=k) = G'_X(1) \end{cases}$$

$$VX = \begin{cases} \int_a^b (x - EX)^2 p_X(x)dx = [\varphi'_X(0)]^2 - \varphi''_X(0) \\ \sum_{k=0}^{\infty} (k - EX)^2 P(X=k) = G''_X(1) + G'_X(1)[1 - G'_X(1)] \end{cases}$$



Funkcje charakterystyczne i tworzące

- Kluczowa własność:

$$\underline{X}, \underline{Y} \text{ niezależne} \Rightarrow \varphi_{X+Y}(v) = \varphi_X(v) \cdot \varphi_Y(v)$$

$$G_{X+Y}(z) = G_X(z) \cdot G_Y(z)$$

Dowód dla funkcji charakterystycznej (dla funkcji tworzącej podobny):

$$\varphi_{X+Y}(v) = E[e^{jv(X+Y)}] = E[e^{jvX} \cdot e^{jvY}] = Ee^{jvX} \cdot Ee^{jvY} = \varphi_X(v) \cdot \varphi_Y(v)$$



$\underline{X}, \underline{Y}$ niezależne $\Rightarrow g(\underline{X})$ i $g(\underline{Y})$ też



Funkcje charakterystyczne i tworzące

- Kluczowa własność:

$$\underline{X}, \underline{Y} \text{ niezależne} \Rightarrow \varphi_{X+Y}(v) = \varphi_X(v) \cdot \varphi_Y(v)$$

$$G_{X+Y}(z) = G_X(z) \cdot G_Y(z)$$

Dowód dla funkcji charakterystycznej (dla funkcji tworzącej podobny):

$$\varphi_{X+Y}(v) = E[e^{jv(X+Y)}] = E[e^{jvX} \cdot e^{jvY}] = Ee^{jvX} \cdot Ee^{jvY} = \varphi_X(v) \cdot \varphi_Y(v)$$



$\underline{X}, \underline{Y}$ niezależne $\Rightarrow g(\underline{X})$ i $g(\underline{Y})$ też

operacja na wielkościach losowych	operacja na rozkładach prawdopodobieństwa	operacja na funkcjach charakterystycznych / tworzących
dodawanie	splot	mnożenie





Funkcje charakterystyczne i tworzące



Przykład: **rozkład normalny** $N(m, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-m)^2 / 2\sigma^2}$

$$\varphi(v) = \int_{-\infty}^{\infty} e^{jvx} \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-m)^2 / 2\sigma^2} dx = \dots = e^{jvm} e^{-\sigma^2 v^2 / 2}$$



Systemy IT i sumy niezależnych wielkości losowych




Funkcje charakterystyczne i tworzące




Przykład: **rozkład normalny** $N(m, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-m)^2 / 2\sigma^2}$


$$\varphi(v) = \int_{-\infty}^{\infty} e^{jvx} \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-m)^2 / 2\sigma^2} dx = \dots = e^{jvm} e^{-\sigma^2 v^2 / 2}$$




$$\Rightarrow \text{splot } N(m_1, \sigma_1), \dots, N(m_n, \sigma_n) = N(m_1 + \dots + m_n, \sqrt{\sigma_1^2 + \dots + \sigma_n^2})$$



suma niezależnych wielkości losowych o rozkładach normalnych:
rozkład normalny



Równoważenie obciążenia: *round robin*



61

Równoważenie obciążenia: *round robin*

Obliczmy rozkład $\underline{J} = I_1 + \dots + I_n$, gdy



$p_I(x)$ – **rozkład wykładniczy** o wartości średniej a .

1) Funkcja charakterystyczna \underline{I} :
$$\varphi_I(v) = \int_0^{\infty} e^{jvx} \frac{e^{-x/a}}{a} dx = \frac{1}{1 - jav}$$

2) Funkcja charakterystyczna \underline{J} :
$$\varphi_J(v) = [\varphi_I(v)]^n = \left(\frac{1}{1 - jav} \right)^n$$

3) Z twierdzenia o jednoznaczności:
$$p_J(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-jtx} \cdot \varphi_J(v) dv$$

trudne...

62



Równoważenie obciążenia: *round robin*



...ale pamiętając, że $\int_0^{\infty} e^{-cx} \frac{x^{n-1}}{(n-1)!} dx = \frac{1}{c^n}$

mamy ($c := 1 - ja v$, $ax := x$): $\varphi_J(v) = \int_0^{\infty} e^{jvx} \frac{(1/a)^n x^{n-1} e^{-x/a}}{(n-1)!} dx = \left(\frac{1}{1 - ja v} \right)^n$



Równoważenie obciążenia: *round robin*




...ale pamiętając, że $\int_0^{\infty} e^{-cx} \frac{x^{n-1}}{(n-1)!} dx = \frac{1}{c^n}$

$$\varphi_x(v) = \int_a^b e^{jvx} p_x(x) dx = \left(\frac{1}{1 - ja v} \right)^n$$


mamy ($c := 1 - ja v$, $ax := x$): $\varphi_J(v) = \int_0^{\infty} e^{jvx} \frac{(1/a)^n x^{n-1} e^{-x/a}}{(n-1)!} dx = \left(\frac{1}{1 - ja v} \right)^n$

gęstość rozkładu J




suma n niezależnych
wielkości losowych
o rozkładach wykładniczych:
rozkład Erlanga- n

Zaległości w obsłudze



Zaległości w obsłudze



- Niech N_t – liczba wywołań w okresie obserwacji.
- Łączny czas przetwarzania tych wywołań = $N_t \cdot \Delta$.
- Jakie jest prawdopodobieństwo naruszenia reżimu czasu rzeczywistego przez procesor przetwarzający wywołania, tj. powstania "zaległości" w chwili t ?

$$P(N_t \cdot \Delta \geq t) = P\left(N_t \geq \left\lceil \frac{t}{\Delta} \right\rceil\right) = ?$$

Zaległości w obsłudze

10 wywołań, 9 interwałów



Zauważmy, że $P(\underline{N}_t \geq n + 1) = P(\underline{I}_1 + \dots + \underline{I}_n < t) = F_n(t)$

dystrybuanta n -krotnego spłotu
rozkładu $p_I(\cdot)$ z samym sobą –
metoda funkcji charakterystycznej!

Zaległości w obsłudze

10 wywołań, 9 interwałów



Zauważmy, że $P(\underline{N}_t \geq n + 1) = P(\underline{I}_1 + \dots + \underline{I}_n < t) = F_n(t)$

dystrybuanta n -krotnego spłotu
rozkładu $p_I(\cdot)$ z samym sobą –
metoda funkcji charakterystycznej!

- $\underline{I} \sim$ rozkład wykładniczy ze średnią a (tj. $p_I(x) = e^{-x/a}/a$)

$$F_n(t) = 1 - e^{-t/a} \sum_{k=0}^{n-1} \frac{(t/a)^k}{k!}$$

dystrybuanta rozkładu
Erlanga- n

- $\underline{I} \sim$ rozkład równomierny w przedziale $[0, 1]$




$$F_n(t) = \sum_{k=0}^{\min\{t, n\}} (-1)^k \frac{(t-k)^n}{k!(n-k)!}$$

dystrybuanta rozkładu
Irwin-Halla

Zaległości w obsłudze

$$P(N_t \geq n+1) = F_n(t)$$

$$\text{Zatem } P(N_t \geq n) = F_{n-1}(t) \Rightarrow P\left(N_t \geq \left\lceil \frac{t}{\Delta} \right\rceil\right) = F_{\lceil t/\Delta \rceil - 1}(t)$$



skąd ta jakościowa różnica?

*jak wyznaczyć rozkład wielkości zaległości?

Utracone wywołania

czasy przetwarzania $\underline{Y}_1, \underline{Y}_2, \dots$:
iid, rozkład wykładniczy
o wartości średniej c
 $p_Y(y) = e^{-y/c}/c$

czas trwania awarii procesora \underline{T} :
rozkład wykładniczy o wartości średniej b
 $p_T(t) = e^{-t/b}/b$


interwały I_1, I_2, \dots :
iid, rozkład wykładniczy
o wartości średniej a
 $p_I(x) = e^{-x/a}/a$

Utracone wywołania

czasy przetwarzania $\underline{Y}_1, \underline{Y}_2, \dots$:
iid, rozkład wykładniczy
o wartości średniej c
 $p_Y(y) = e^{-y/c}/c$


czas trwania awarii procesora \underline{T} :
rozkład wykładniczy o wartości średniej b
 $p_T(t) = e^{-t/b}/b$

interwały $\underline{I}_1, \underline{I}_2, \dots$:
iid, rozkład wykładniczy
o wartości średniej a
 $p_I(x) = e^{-x/a}/a$



- Problem 1: Ile wywołań utracimy w czasie awarii \underline{T} ?
- oznaczmy tę wielkość losową \underline{N}_T ("podwójna" losowość!)
- Problem 2: Ile czasu przetwarzania utracimy w czasie awarii \underline{T} ?
- wielkość losowa $\underline{S} = \underline{Y}_1 + \dots + \underline{Y}_{N_T}$ ("potrójna" losowość!)

Utracone wywołania



- Problem 1: Ile wywołań utracimy w czasie awarii \underline{T} ?



- ze wzoru na **prawdopodobieństwo całkowite**:

$$\begin{aligned}
 P(\underline{N}_T = n) &= \int_0^{\infty} P(\underline{N}_T = n \mid t \leq \underline{T} < t + dt) P(t \leq \underline{T} < t + dt) \\
 &= \int_0^{\infty} P(\underline{N}_t = n) p_T(t) dt
 \end{aligned}$$

Utracone wywołania



- **Problem 1:** Ile wywołań utracimy w czasie awarii T ?



- ze wzoru na **prawdopodobieństwo całkowite**:

$$\begin{aligned}
 P(N_T = n) &= \int_0^{\infty} P(N_T = n \mid t \leq T < t + dt) P(t \leq T < t + dt) \\
 &= \int_0^{\infty} P(N_t = n) p_T(t) dt
 \end{aligned}$$

$$P(N_t \geq n) - P(N_t \geq n+1) = F_{n-1}(t) - F_n(t)$$

z przykładu o zaległościach w obsłudze mamy $F_n(t)$, tj. $P(L_1 + \dots + L_n < t)$

Utracone wywołania


$$F_n(t) = 1 - e^{-t/a} \sum_{k=0}^{n-1} \frac{(t/a)^k}{k!}$$

- Dla rozkładu wykładniczego I :



$$P(N_t = n) = \frac{(t/a)^n}{n!} e^{-t/a}, \quad n = 0, 1, 2, \dots$$

rozkład Poissona



Utracone wywołania


$$F_n(t) = 1 - e^{-t/a} \sum_{k=0}^{n-1} \frac{(t/a)^k}{k!}$$

- Dla rozkładu wykładniczego \underline{I} :



$$P(N_t = n) = \frac{(t/a)^n}{n!} e^{-t/a}, \quad n = 0, 1, 2, \dots$$

rozkład Poissona



- Zatem: $P(N_T = n) = \int_0^\infty \frac{(t/a)^n}{n!} e^{-t/a} \frac{e^{-t/b}}{b} dt = \dots = (1-r)^n r, \quad n = 0, 1, 2, \dots$



rozkład geometryczny

gdzie $r = \frac{a}{a+b}$


wartość średnia: $EN_T = \sum_{n=0}^{\infty} n P(N_T = n) = \frac{1-r}{r} = \frac{b}{a}$



Utracone wywołania

- Problem 2: Ile czasu przetwarzania utracimy w czasie awarii \underline{T} ?

$$S = Y_1 + \dots + Y_{N_T}$$



$$\underline{N_T}: \text{r. geometryczny } (1-r)^n r \quad (r = a/(a+b)); \quad G_{N_T}(z) = \sum_{n=0}^{\infty} z^n P(N_T = n) = \frac{r}{1-(1-r)z}$$

$$\underline{Y_1}, \underline{Y_2}, \dots: \varphi_Y(v) = \frac{1}{1-jcv}$$



Utracone wywołania

- **Problem 2:** Ile czasu przetwarzania utracimy w czasie awarii \underline{T} ?

$$\underline{S} = \underline{Y}_1 + \dots + \underline{Y}_{\underline{N}_T}$$



\underline{N}_T : r. geometryczny $(1-r)^n r$ (gdzie $r = b/a$); $G_{N_T}(z) = \sum_{n=0}^{\infty} z^n P(\underline{N}_T = n) = \frac{r}{1 - (1-r)z}$

$$\underline{Y}_1, \underline{Y}_2, \dots: \varphi_Y(v) = \frac{1}{1 - jc v}$$

- Korzystając z kluczowej własności funkcji charakterystycznych oraz na podstawie **twierdzenia o średniej warunkowej** nietrudno udowodnić, że

jeżeli $\underline{S} = \underline{Y}_1 + \dots + \underline{Y}_{\underline{N}}$, gdzie $\underline{Y}_i \sim \underline{Y}$ są iid

suma losowa
wielkości losowych iid

to $\varphi_S(v) = G_N[\varphi_Y(v)]$

$$\begin{aligned} \text{Gdyż: } \varphi_S(v) &= E e^{jv\underline{S}} = \sum_{n=1}^{\infty} E e^{jv\underline{S}} P(\underline{N} = n) = \sum_{n=1}^{\infty} E e^{jv(\underline{Y}_1 + \dots + \underline{Y}_n)} P(\underline{N} = n) \\ &= \sum_{n=1}^{\infty} [\varphi_Y(v)]^n P(\underline{N} = n) = G_N[\varphi_Y(v)] \end{aligned}$$

Utracone wywołania

$$G_{N_T}(z)$$

$$\bullet \text{ Zatem: } \varphi_S(v) = \frac{r}{1 - (1-r)z} \bigg|_{z = \frac{1}{1 - jc v}} = \dots = r + (1-r) \cdot \frac{1}{1 - j \frac{c}{r} v} = r \cdot e^{jv0} + (1-r) \cdot \frac{1}{1 - j \frac{c}{r} v}$$

$$\varphi_Y(v)$$

Utracone wywołania

$$\bullet \text{ Zatem: } \varphi_S(v) = \frac{r}{1-(1-r)z} \bigg|_{z=\frac{1}{1-jcv}} = \dots = r + (1-r) \cdot \frac{1}{1-j\frac{c}{r}v} = r \cdot \overbrace{e^{jv0}}^{\int_0^\infty e^{jvs} (p_1(s) + p_2(s)) ds} + (1-r) \cdot \frac{1}{1-j\frac{c}{r}v}$$

$p_2(s)$: kształt wykładniczy
 jakie $p_1(s)$ odpowiada $r \cdot e^{jv0}$?

Utracone wywołania

$$\bullet \text{ Zatem: } \varphi_S(v) = \frac{r}{1-(1-r)z} \bigg|_{z=\frac{1}{1-jcv}} = \dots = r + (1-r) \cdot \frac{1}{1-j\frac{c}{r}v} = r \cdot \overbrace{e^{jv0}}^{\int_0^\infty e^{jvs} (p_1(s) + p_2(s)) ds} + (1-r) \cdot \frac{1}{1-j\frac{c}{r}v}$$

$p_2(s)$: kształt wykładniczy
 jakie $p_1(s)$ odpowiada $r \cdot e^{jv0}$?

$$r \cdot e^{jv0} = r = \int_0^\infty e^{jvs} p_1(s) ds \Rightarrow \text{funkcja skupiona w } s = 0$$

$$v = 0 \Rightarrow \text{całka} = r$$

Utracone wywołania


$$\bullet \text{ Zatem: } \varphi_S(v) = \frac{r}{1 - (1-r)z} \bigg|_{z = \frac{1}{1-jcv}} = \dots = r + (1-r) \cdot \frac{1}{1 - j\frac{c}{r}v} = r \cdot \underbrace{e^{jv0}}_{\int_0^\infty e^{jvs} (p_1(s) + p_2(s)) ds} + (1-r) \cdot \frac{1}{1 - j\frac{c}{r}v}$$

$p_2(s)$: kształt wykładniczy

jakie $p_1(s)$ odpowiada $r \cdot e^{jv0}$?

$$r \cdot e^{jv0} = r = \int_0^\infty e^{jvs} p_1(s) ds \Rightarrow \text{funkcja skupiona w } s = 0$$

$v = 0 \Rightarrow \text{całka} = r$



$$\text{wartość średnia: } E\Sigma = \frac{\varphi'_s(0)}{j} = \frac{b}{a} \cdot c$$

Opróżnianie stosu



Do pustego stosu przybywa przerwanie.
Czy stos opróżni się ponownie?

W tym celu musi zakończyć się obsługa pierwszego przerwania oraz wszystkich jego potomków.

Do potomków przerwania zaliczamy przerwanie przybyłe w trakcie jego obsługi oraz wszystkich potomków tych przerw.


Opróżnianie stosu



Do pustego stosu przybywa przerwanie.
Czy stos opróżni się ponownie?

W tym celu musi zakończyć się obsługa pierwszego przerwania oraz wszystkich jego potomków.

Do potomków przerwania zaliczamy przerwanie przybyłe w trakcie jego obsługi oraz wszystkich potomków tych przerwania.



Opróżnianie stosu



Do pustego stosu przybywa przerwanie.
Czy stos opróżni się ponownie?



W tym celu musi zakończyć się obsługa pierwszego przerwania oraz wszystkich jego potomków.

Do potomków przerwania zaliczamy przerwanie przybyłe w trakcie jego obsługi oraz wszystkich potomków tych przerwania.

- Niech $\underline{N} \in \{0, 1, 2, \dots\}$ reprezentuje liczbę bezpośrednich potomków przerwania.
- Załóżmy, że interwały w strumieniu przerwania oraz czasy obsługi przerwania są iid.
- Jeśli znamy rozkłady: interwałów i czasów obsługi przerwania, to znamy także rozkład \underline{N} i jego funkcję tworzącą $G_{\underline{N}}(z)$.
- Mamy $G_{\underline{N}}(1) = \sum_{k=0}^{\infty} P(\underline{N} = k) = 1$
- Przyjmijmy $P(\underline{N} = 0) < 1$ i $P(\underline{N} = 1) < 1$ – inaczej problem jest trywialny...




Opróżnianie stosu

- Niech $\underline{Y}^{(j)}$: liczebność pokolenia numer j
- $\underline{Y}^{(0)} = 1, \underline{Y}^{(1)} \sim N$




Opróżnianie stosu

- Niech $\underline{Y}^{(j)}$: liczebność pokolenia numer j
- $\underline{Y}^{(0)} = 1, \underline{Y}^{(1)} \sim N$
- dla $j > 0$: $\underline{Y}^{(j)} \in \{0, 1, 2, \dots\}$ – możliwe jest $\underline{Y}^{(\infty)} = \infty$



Opróżnianie stosu



- Niech $\underline{Y}^{(j)}$: liczebność pokolenia numer j
- $\underline{Y}^{(0)} = 1$, $\underline{Y}^{(1)} \sim N$
- dla $j > 0$: $\underline{Y}^{(j)} \in \{0, 1, 2, \dots\}$, gdyż możliwy jest nieograniczony rozrost populacji
- Z rysunku widać, że:

$$\underline{Y}^{(j)} = \underline{Y}_1^{(j-1)} + \dots + \underline{Y}_N^{(j-1)}$$

= łączna liczebność pokoleń numer $j - 1$
wywodzących się od bezpośrednich potomków
pierwszego przerwania

- $\underline{Y}_k^{(j-1)}$ są iid



Opróżnianie stosu



- Korzystając z z kluczowej własności funkcji tworzących oraz z **twierdzenia o średniej warunkowej** nietrudno udowodnić, że

jeżeli $\underline{S} = \underline{Y}_1 + \dots + \underline{Y}_N$, gdzie $\underline{Y}_k \sim \underline{Y}$ są iid

to $G_S(z) = G_N[G_Y(z)]$

suma losowa
dyskretnych wielkości
losowych iid

$$\begin{aligned} \text{Gdyż: } G_S(z) &= E z^{\underline{S}} = \sum_{k=0}^{\infty} E z^{\underline{S}} P(\underline{N} = k) = \sum_{k=0}^{\infty} E z^{\underline{Y}_1 + \dots + \underline{Y}_k} P(\underline{N} = k) \\ &= \sum_{k=0}^{\infty} [G_Y(z)]^k P(\underline{N} = k) = G_N[G_Y(z)] \end{aligned}$$



Opróżnianie stosu



- Korzystając z kluczowej własności funkcji tworzących oraz z **twierdzenia o średniej warunkowej** nietrudno udowodnić, że

jeżeli $\underline{S} = \underline{Y}_1 + \dots + \underline{Y}_N$, gdzie $\underline{Y}_k \sim \underline{Y}$ są iid

to $G_S(z) = G_N[G_Y(z)]$

*suma losowa
dyskretnych wielkości
losowych iid*

$$\begin{aligned} \text{Gdyż: } G_S(z) &= E z^{\underline{S}} = \sum_{k=0}^{\infty} E z^{\underline{S}} P(\underline{N} = k) = \sum_{k=0}^{\infty} E z^{\underline{Y}_1 + \dots + \underline{Y}_k} P(\underline{N} = k) \\ &= \sum_{k=0}^{\infty} [G_Y(z)]^k P(\underline{N} = k) = G_N[G_Y(z)] \end{aligned}$$

- Ponieważ w naszym problemie mamy $\underline{Y}^{(j)} = \underline{Y}_1^{(j-1)} + \dots + \underline{Y}_N^{(j-1)}$, więc

$$G_{Y^{(j)}}(z) = G_N[G_{Y^{(j-1)}}(z)], \quad j = 1, 2, \dots$$

oraz $G_{Y^{(0)}}(z) = z$



Opróżnianie stosu

- Przykład: $P(\underline{N} = 0) = 0.3, P(\underline{N} = 1) = 0.4, P(\underline{N} = 2) = 0.2, P(\underline{N} = 3) = 0.1$

$$G_{Y^{(0)}}(z) = z$$

$$G_{Y^{(1)}}(z) = G_N[G_{Y^{(0)}}(z)] = G_N(z) = 0.3 + 0.4z + 0.2z^2 + 0.1z^3$$



Opróżnianie stosu



- Przykład: $P(\underline{N} = 0) = 0.3, P(\underline{N} = 1) = 0.4, P(\underline{N} = 2) = 0.2, P(\underline{N} = 3) = 0.1$

$$G_{Y^{(0)}}(z) = z$$

$$G_{Y^{(1)}}(z) = G_N[G_{Y^{(0)}}(z)] = G_N(z) = 0.3 + 0.4z + 0.2z^2 + 0.1z^3$$

$$G_{Y^{(2)}}(z) = G_N[G_{Y^{(1)}}(z)]$$

$$= G_N(0.3 + 0.4z + 0.2z^2 + 0.1z^3)$$

$$= 0.3$$

$$+ 0.4(0.3 + 0.4z + 0.2z^2 + 0.1z^3)$$

$$+ 0.2(0.3 + 0.4z + 0.2z^2 + 0.1z^3)^2$$

$$+ 0.1(0.3 + 0.4z + 0.2z^2 + 0.1z^3)^3$$

$$= 0.4407 + 0.2188z + \dots + 0.0024z^7 + 0.0006z^8 + 0.0001z^9$$

Opróżnianie stosu



- $\Pi = P(\text{stos opróżni się ponownie}) = P(\text{populacja ostatecznie wymrze})$

$$= P(Y^{(\infty)} = 0) = G_{Y^{(\infty)}}(0)$$

$$G_{Y^{(j)}}(z) = G_N[G_{Y^{(j-1)}}(z)], \quad j = 1, 2, \dots$$

- Podstawiając $z = 0$ otrzymujemy w granicy

$$G_{Y^{(\infty)}}(0) = G_N[G_{Y^{(\infty)}}(0)] \Leftrightarrow \Pi = G_N[\Pi]$$

na przykład:

$$\begin{aligned} \Pi &= 0.35 + 0.4\Pi + 0.15\Pi^2 + 0.1\Pi^3 \\ \Pi &= 0.3 + 0.4\Pi + 0.2\Pi^2 + 0.1\Pi^3 \end{aligned}$$

Opróżnianie stosu

- $\Pi = P(\text{stos opróżni się ponownie}) = P(\text{populacja ostatecznie wymrze})$
 $= P(Y^{(\infty)} = 0) = G_{Y^{(\infty)}}(0)$

$$G_{Y^{(j)}}(z) = G_N[G_{Y^{(j-1)}}(z)], \quad j = 1, 2, \dots$$


- Podstawiając $z = 0$ otrzymujemy w granicy

$$G_{Y^{(\infty)}}(0) = G_N[G_{Y^{(\infty)}}(0)] \Leftrightarrow \Pi = G_N[\Pi]$$

- $G_N(z)$: niemalejąca i wypukła funkcja z
 (wielomian o współczynnikach ≥ 0)
 - 1 jest zawsze jednym z rozwiązań
 - ...jedynym, gdy $G'_N(1) = EN \leq 1$

- Jeżeli $EN \leq 1$, to stos opróżni się ponownie z prawdopodobieństwem 1 (prawie na pewno)

- Co gdy $EN > 1$? Które rozwiązanie?



Opróżnianie stosu

- Jeżeli w jest jakąkolwiek liczbą z przedziału $[0,1]$ spełniającą równanie $w = G_N(w)$,
 to dla każdego j zachodzi: $G_{Y^{(j)}}(0) \leq w$

Dowód przez indukcję zupełną względem j :

$$G_{Y^{(0)}}(0) = 0 \leq w$$

$$G_{Y^{(j-1)}}(0) \leq w \Rightarrow G_{Y^{(j)}}(0) = G_N[G_{Y^{(j-1)}}(0)] \leq G_N(w) = w$$


Opróżnianie stosu

- Jeżeli w jest jakaikolwiek liczbą z przedziału $[0,1]$ spełniającą równanie $w = G_N(w)$, to dla każdego j zachodzi: $G_{Y^{(j)}}(0) \leq w$

Dowód przez indukcję zupełną względem j :

$$G_{Y^{(0)}}(0) = 0 \leq w$$

$$G_{Y^{(j-1)}}(0) \leq w \Rightarrow G_{Y^{(j)}}(0) = G_N[G_{Y^{(j-1)}}(0)] \leq G_N(w) = w$$



- Zatem jeżeli $EN > 1$, to prawdopodobieństwo ponownego opróżnienia stosu jest najmniejszym rozwiązaniem ww. równania (czyli istnieje niezerowe prawdopodobieństwo, że stos nie opróżni się już nigdy)



Opróżnianie stosu

$$\Pi = G_N[\Pi]$$

na przykład:

$$\Pi = 0.35 + 0.4\Pi + 0.15\Pi^2 + 0.1\Pi^3 \quad (EN = 1.0) \Rightarrow \Pi = 1$$

$$\Pi = 0.3 + 0.4\Pi + 0.2\Pi^2 + 0.1\Pi^3 \quad (EN = 1.1) \Rightarrow \Pi = 0.791 \text{ lub } \Pi = 1$$





Opróżnianie stosu

$$\Pi = G_N[\Pi]$$

na przykład:

$$\Pi = 0.35 + 0.4\Pi + 0.15\Pi^2 + 0.1\Pi^3 \quad (EN = 1.0) \Rightarrow \Pi = 1$$

$$\Pi = 0.3 + 0.4\Pi + 0.2\Pi^2 + 0.1\Pi^3 \quad (EN = 1.1) \Rightarrow \Pi = 0.791 \text{ lub } \Pi = 1$$



spróbujemy ambitniej?

Jaki rozkład prawdopodobieństwa ma $Y^{(\infty)}$?



Opróżnianie stosu

Jaki rozkład prawdopodobieństwa ma $Y^{(\infty)}$?

Wracamy do równania $G_{Y^{(j)}}(z) = G_N[G_{Y^{(j-1)}}(z)]$, $j = 1, 2, \dots$

– co możemy z niego wynioskować?

Jeżeli istnieje granica $G_{Y^{(\infty)}}(z)$, to spełnia równanie

$$G_{Y^{(\infty)}}(z) = G_N[G_{Y^{(\infty)}}(z)]$$

na przykład:

$$G_{Y^{(\infty)}}(z) = 0.3 + 0.4G_{Y^{(\infty)}}(z) + 0.2(G_{Y^{(\infty)}}(z))^2 + 0.1(G_{Y^{(\infty)}}(z))^3$$

Opróżnianie stosu

Jaki rozkład ma $\underline{Y}^{(\infty)}$?

Wracamy do równania $G_{Y^{(j)}}(z) = G_N[G_{Y^{(j-1)}}(z)]$, $j = 1, 2, \dots$

– co możemy z niego wywnioskować?

Jeżeli istnieje granica $G_{Y^{(\infty)}}(z)$, to spełnia równanie

$$G_{Y^{(\infty)}}(z) = G_N[G_{Y^{(\infty)}}(z)]$$

na przykład:

$$G_{Y^{(\infty)}}(z) = 0.3 + 0.4G_{Y^{(\infty)}}(z) + 0.2(G_{Y^{(\infty)}}(z))^2 + 0.1(G_{Y^{(\infty)}}(z))^3$$

$$\Rightarrow G_{Y^{(\infty)}}(z) = \text{const.}$$

$$G_{Y^{(\infty)}}(z) = P(\underline{Y}^{(\infty)} = 0) + P(\underline{Y}^{(\infty)} = 1)z + P(\underline{Y}^{(\infty)} = 2)z^2 + P(\underline{Y}^{(\infty)} = 3)z^3 + P(\underline{Y}^{(\infty)} = 4)z^4 + \dots$$

a zatem...?!